

Criterio para la selección de variables:

Como se muestra en el archivo de exploración, rápidamente descarté variables que fueran netamente ID o identificadores, ya que aportan valor como registros en base de datos, pero no necesariamente aportan al modelo de machine learning. Aunque uno de las variables ID que quise dejar fue la del storage id, esto porqué esta variable esta directamente relacionado con si es una tienda o no, siendo así la mayoría de tiendas vendedoras de productos nuevos, a excepción de las tiendas que venden usados.

Realicé un proceso de análisis de las variables interesantes, transformación de estas y revisión de sus estructuras con respecto a la variable objetivo.

La mayoría convirtiéndose en variables categóricas a excepción de unas cuantas que se eran numéricas o de valores continuos.

Eliminé también variables que estuvieran en muy pocos registros, ya que posiblemente no suelen aparecer y no me den mucho valor.

Las variables textuales como garantía y titulo las analice con 2 métodos distintos, hice un análisis previo de la garantía buscando cuales categorías podrían usarse, luego las agrupé mas aún para generar clases a parte de cuando hubiese garantía o no, teniendo presente que la mayoría de veces para productos nuevos de alto valor suele haber garantías.

Con respecto al titulo, se analizó con un modelo mas tradicional de conteo de palabras, relaciones, categorías propuestas y embeddings, finalmente se generó un modelo propio para esto y con ese se extrapoló a todos los datos.

Por lo que mi criterio principal fue la relación que tenían con la variable objetivo, la correlación que tuviesen entre variables, y quitar los IDs o variables de posición en bases de datos.

Selección de la métrica secundaria:

Para este problema después de ejecutar el modelado se utilizaron modelos basados en árboles, en particular los mejores fueron:

LightGBM: 0.8772 (tiempo: 801.8s)

GradientBoosting: 0.8754 (tiempo: 995.9s)

RandomForest: 0.8720 (tiempo: 204.6s)

Los tiempos de ejecución se deben al grid search extenso, se utilizaron modelos basados en arboles debido a que los datos fueron principalmente categóricos en la selección que hice, y los arboles se comportan bien con estas variables.

En este caso el LightGBM fue el mejor con las métricas:

Reporte de clasificación:

	precision	recall	f1-score	support
0	0.90	0.86	0.88	5406
1	0.85	0.89	0.87	4594
accuracy			0.88	10000
macro avg	0.88	0.88	0.88	10000
weighted avg	0.88	0.88	0.88	10000

La métrica secundaria escogida para indicar que modelo guardar es el recall, porque el recall, el modelo indica que pueda identificar correctamente el 89% de los productos usados.

Un producto usado vendido como nuevo es el error más grave desde la perspectiva del cliente, esto afecta directamente la confianza del Marketplace, y puede tener consecuencias legales.

Aunque un 11% todavía se clasifican mal lo que puede conllevar un riesgo significativo.

Por esto el recall es una métrica muy relevante para este caso, cuando los porcentajes de las probabilidades no sean claros del todo, podríamos clasificar ese producto como riesgoso, y llevarlo a otro análisis.